

# **A DETEÇÃO REMOTA NA CLASSIFICAÇÃO DO USO DO SOLO**

## **Análise das potencialidades da utilização das imagens de satélite**

**Ângela Silva**

**2020**



## Índice

1. Introdução.....	3
1.1 Objetivos .....	4
1.2 Metodologia.....	4
1.2.1 Enquadramento da área de estudo .....	4
1.2.2 Dados e métodos .....	5
2. A detecção remota: princípios e conceitos teóricos básicos.....	7
2.1 Radiação eletromagnética e interação energia-matéria .....	8
2.2 Os tipos de resolução dos sensores .....	9
3. Satélites e sensores.....	10
4. Processamento e análise de imagem.....	12
4.1 Pré-processamento .....	12
4.2 Operações de melhoramento de imagem .....	12
4.3 Classificação de imagem .....	13
4.3.1 Classificação supervisionada.....	14
4.3.2 Classificação não-supervisionada .....	14
4.4 Avaliação da precisão da classificação.....	14
5. Apresentação e discussão dos resultados .....	15
6. Conclusão.....	20
6. Referências Bibliográficas .....	20

# 1. Introdução

A detecção remota é uma ciência que permite responder de forma rápida, com baixo custo e grande precisão aos desafios do dia-a-dia (Nandaia, 2015). Permite obter informação sobre um determinado objeto, área ou fenômeno através dos dados que sensores adquirem sem necessidade de estes estarem em contato com o objeto, área ou fenômeno. Tem aplicabilidade em diversos domínios (Lillesand et al., 2015), neste caso em concreto, no planeamento e ordenamento do território (uso e ocupação do solo).

Os sensores podem estar colocados em três grandes tipos de plataformas; neste caso importa referir os sensores colocados em plataformas espaciais (satélites), no entanto há parâmetros que os distinguem, nomeadamente em termos de resolução espacial, temporal e, em alguns casos, radiométrica (Cracknell & Hayes, 2007; Jensen, 2014; Lillesand et al., 2015). Destaca-se o programa LANDSAT, SPOT e Copernicus. Neste último estão incluídos os satélites Sentinel. No decorrer deste trabalho apenas vão ser utilizadas imagens provenientes do Sentinel-2.

Um dos primeiros passos a considerar para uma correta utilização destas imagens, nomeadamente para classificação do uso e ocupação do solo, é a sua correção. As imagens captadas possuem distorções que podem estar relacionadas com a rotação da Terra e distância do satélite à Terra; Fala-se, portanto, de processamento de imagens, que permite extrair, manipular e quantificar a informação temática das imagens (Amorim, 2015; Pinho, 2009; Ribeiro, 2008). Os principais procedimentos a ter em consideração são: descarregar a imagem de satélite; analisar a qualidade dos dados; manipular os dados; corrigir a imagem; efetuar operações de melhoramento; efetuar a classificação da imagem e, por fim, avaliar a precisão da classificação.

A classificação da imagem é um dos processos mais complexos e permite categorizar de forma automática todos os píxeis de uma imagem em classes de uso do solo (Cracknell & Hayes, 2007; Lillesand et al., 2015; Nandaia, 2015). Apesar de poderem ser utilizados diferentes tipos de classificação de imagem, importa destacar a classificação supervisionada, em que é feita uma análise espectral das características dos elementos da imagem; É considerado o tipo de classificação que apresenta menor erro e maior precisão, contudo, implica que o operador tenha um bom conhecimento da área em estudo e que a separabilidade das classes seja máxima (Lillesand et al., 2015).

No decorrer deste trabalho a área de estudo será o município de Arouca, que apresenta características físicas interessantes para o estudo do uso e ocupação do solo. Além disso, constitui-se um exemplo interessante para, em trabalhos futuros, estudar questões relacionadas com os riscos naturais, como é o exemplo dos incêndios rurais. Isto porque é um concelho com elevada recorrência

de incêndios, onde se destacam os anos de 2005 e 2016 com registo de incêndios considerados extremos.

## **1.1 Objetivos**

De acordo com os objetivos da unidade curricular, e com as competências de aprendizagem associadas, o objetivo central deste trabalho é: classificar duas imagens de satélite (Sentinel-2) relativas à ocupação do solo em épocas do ano distintas (verão e inverno) para o município de Arouca, e identificar potenciais mudanças.

Para a sua concretização foram definidos os seguintes objetivos específicos:

1. Análise de conteúdos teóricos relacionados com o tema em estudo, que permitam complementar a informação adquirida ao longo das aulas lecionadas;
2. Análise das características físicas do município em estudo, de modo a facilitar a seleção das áreas de treino para a classificação da imagem;
3. Cálculo do índice de vegetação NDVI e das classes de ocupação do solo com base nas imagens de satélite.

## **1.2 Metodologia**

### **1.2.1 Enquadramento da área de estudo**

O município de Arouca (figura1) é a área de estudo deste trabalho. Este integra a região Norte de Portugal Continental e a Área Metropolitana do Porto. Localiza-se no extremo nordeste do distrito de Aveiro e faz fronteira com os municípios de São Pedro do Sul, Castro Daire, Cinfães, Castelo de Paiva, Gondomar, Santa Maria da Feira, Oliveira de Azeméis e Vale de Cambra. Este município é constituído por dezasseis freguesias (Alvarenga, Chave, Escariz, Fermedo, Mansores, Moldes, Rossas, Santa Eulália, São Miguel do Mato, Tropeço, Urrô, Várzea e pelas União de Freguesias (UF) de Cabreiros e Albergaria da Serra, de Canelas e Espiunca, e de Covelo de Paivó e Janarde) e possui uma área de 329,11 Km<sup>2</sup> (Tabela 1). À data dos CENSOS 2011 este município albergava uma população residente de 22 359 habitantes (INE, 2011) com previsão que esta seja inferior nos próximos censos.

Este município é constituído essencialmente por espaços florestais (80% da área municipal segundo a COS 2007)(Correia, 2017; Magalhães, 2018) e é um território classificado pertencendo à rede mundial de Geoparques da Unesco, e 15 498 ha do município integrados em espaço Rede Natura 2000 (RN 2000), 47% da área municipal, onde se inclui três Sítios de Interesse Comunitário (SIC's) ("Serra da Freita e Arada"; "Rio Paiva" e "Serra do Montemuro") (Correia, 2017) (figura 1).

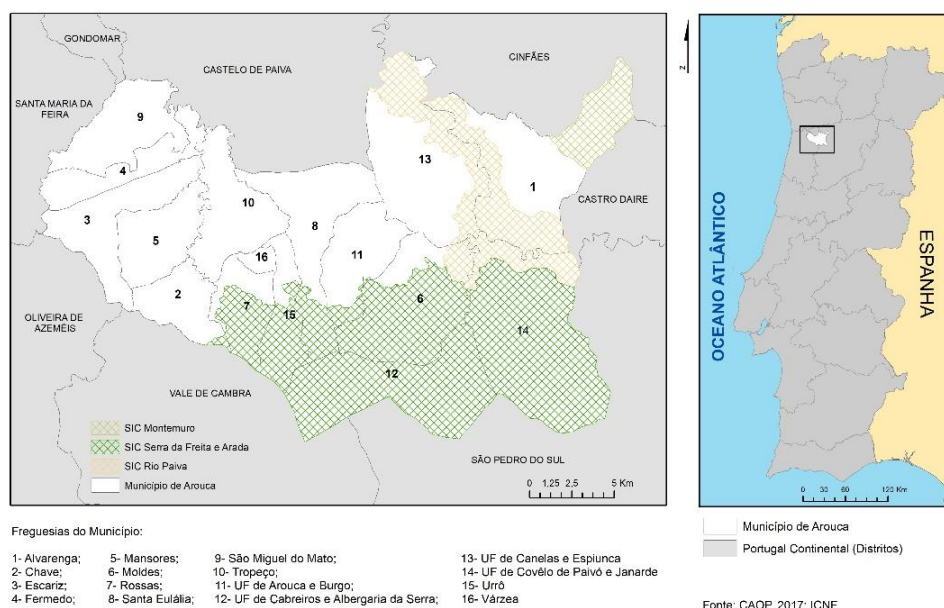


Figura 1- Rede Natura 2000 (SIC's) no município de Arouca. Fonte: Elaboração própria.

Tabela 1- Área das freguesias do município de Arouca.

Freguesia	Área (km <sup>2</sup> )
Alvarenga	38,76
Chave	10,91
Escariz	17,98
Fervedo	11,10
Mansores	14,08
Moldes	28,01
Rossas	11,11
Santa Eulália	23,05
São Miguel do Mato	17,10
Tropeço	17,84
Urrô	10,79
Várzea	1,79
UF de Arouca e Burgo	15,25
UF de Cabreiros e Albergaria da Serra	31,23
UF de Canelas e Espiunca	35,73
UF de Covêlo de Paivó e Janarde	44,38
Total	329,11

Fonte:(Magalhães, 2018).

### 1.2.2 Dados e métodos

A metodologia adotada neste estudo foi adaptada ao objetivo do trabalho, recorrendo-se a uma metodologia multi-métodos.

Foi feita uma revisão bibliográfica sobre a deteção remota, que compila diversa informação que explica a base teórica necessária para a realização de alguns dos procedimentos apresentados nos resultados deste trabalho.

Procedeu-se à escolha da área de estudo e posteriormente, através da plataforma online do Copernicus, foi feita a recolha das imagens Sentinel-2 referentes a duas épocas distintas do ano de 2019, verão (3 de agosto) e inverno (5 de janeiro). A imagem referente à época quente do ano apresenta uma cobertura de nuvens de 5,4%, cerca de 58,6% de vegetação e 17,8% de água. A imagem

referente à época fria apresenta uma cobertura de nuvens de 0,9%, cerca de 50,9% de vegetação e 22,6% de água. Contudo, as imagens recolhidas deste portal apenas foram utilizadas para a realização do cálculo de NDVI, pois apresentaram problemas no software QGIS, mais concretamente ao efetuar a correção do Digital Number (fase de pré-processamento) no plugin Semi-automatic Classification. Como tentativa de resolução deste problema, procedeu-se à recolha de imagens Sentinel-2 no portal de dados USGS Earth Explorer que funciona com o plugin Semi-automatic Classification. A imagem referente ao período frio é exatamente a mesma utilizada para o cálculo do NDVI, contudo a imagem do período quente teve de ser alterada, pois esta plataforma não tinha disponível a mesma imagem que foi recolhida para o cálculo do NDVI. A nova imagem é referente ao dia 12 de setembro de 2019.

No processamento de imagem realizou-se o recorte das bandas com resolução espacial de 10 e 20 metros para a área de estudo definida, de modo a poder realizar um conjunto de operações, nomeadamente o cálculo do índice NDVI e a classificação de imagem.

Para o cálculo do NDVI selecionaram-se as bandas 8, infravermelho próximo (NIR), e 4, vermelho, que apresentam resolução espacial de 10 metros. Recorreu-se ao software QGIS, versão 3.10.1 e no comando raster calculator calculou-se a seguinte equação:  $(\text{NIR} - \text{vermelho}) / (\text{NIR} + \text{vermelho})$ . Após verificar se os dados estavam corretos, se apresentavam valores entre -1 e 1, procedeu-se à classificação dos mesmos. Foram consideradas cinco classes (muito baixo; baixo; moderado; elevado; e muito elevado), pelo que valores mais próximos de 1 indicam grande atividade fotossintética e valores mais próximos de -1, ausência de vegetação. Este procedimento foi realizado para as duas épocas do ano consideradas.

Para a realização da classificação foi utilizada a classificação supervisionada, orientada ao pixel. Num primeiro momento foram adicionadas as bandas 2,3,4,5,6,7,8,8A,11 e 12 para a criação do raster virtual. Posteriormente, foram calculadas todas as combinações RGB e definida a combinação 3-2-1, correspondente à cor verdadeira, de modo a facilitar a identificação dos objetos para definir as áreas de treino. Procedeu-se à conversão do Digital Number (DN) para refletância, através do método Dark Object Subtraction (DOS). Definiram-se as áreas de treino tendo em consideração 4 macroclasses (Territórios artificializados; Áreas agrícolas e agro-florestais; Florestas e meios naturais e semi-naturais; Corpos de água) e 7 classes (Tecido urbano; Pastagens permanentes; Áreas agrícolas heterogêneas; Florestas; Florestas abertas e vegetação arbustiva e herbácea; Zonas descobertas ou com pouca vegetação; Águas interiores). Por fim foram gerados relatórios de classificação tendo em consideração três métodos distintos: minimum distance, maximum likelihood e spectral Angle Mapping. Estes métodos foram considerados nos procedimentos de pós-processamento, o que gerou uma matriz de confusão, permitindo-nos saber o grau de exatidão da classificação. No final deste procedimento apenas foi considerado o método que apresentou menor erro. Todos estes

procedimentos referidos anteriormente foram realizados para as duas imagens. Para a avaliação da precisão da classificação foi considerado o grau de exatidão e o fator kappa.

A análise da ocupação do solo necessitou do uso de duas ferramentas de produção cartográfica, o QGIS 3.10.1 e o ArcMap 10.7.1. Numa primeira fase foi feito o processo de classificação da imagem no QGIS que deu origem a um raster. O mesmo raster foi importado no ArcGis, uma vez que este software gera tabela de atributos para raster, e foi contabilizado o número de pixels de cada classe tendo em consideração que o tamanho do pixel é de 10 por 10 metros. Isto permitiu saber quantos hectares tem cada classe de uso do solo para o município em análise.

## **2. A deteção remota: princípios e conceitos teóricos básicos**

A deteção remota é uma ciência capaz de responder de forma rápida, com baixo custo e grande precisão, aos desafios do dia-a-dia (Nandaia, 2015). Segundo Lillesand, Kiefer, & Chipman (2015), é considerada a arte e a ciência de obter informação sobre um objeto, área ou fenómeno, através da análise de dados adquiridos por um sensor que não está em contato com o objeto, área ou fenómeno em análise. Este sensor mede a interação entre a matéria e a energia eletromagnética e pode estar colocado em três grandes tipos de plataformas: terrestres, aéreas ou espaciais (Amorim, 2015; Pinho, 2009; Ribeiro, 2008). “Para além da aquisição de dados, a deteção remota engloba também o seu processamento e interpretação” (Pinho, 2009, p.11). O processamento detém um conjunto de técnicas que permitem transformar os dados obtidos em imagens e a interpretação permite converter uma imagem em informação importante e útil para diversas aplicações (Pinho, 2009). No processo de aquisição podemos enumerar um conjunto de elementos: fonte de radiação; interação com a atmosfera; interação com o objeto; recolha de radiação pelo sensor; transmissão, receção e processamento; interpretação e análise; e as diversas aplicações (Amorim, 2015) (figura 2). “Assim, a ciência disponibiliza os instrumentos e a teoria para compreender a forma como os objetos e os fenómenos podem ser detetados e a arte consiste no desenvolvimento e utilização de técnicas de análise para gerar informação útil” (Ribeiro, 2008, p.37).

A deteção remota pode ser aplicada em diversos domínios tais como: gestão dos recursos naturais; estudos cartográficos; estudos geológicos e de pesquisa mineira; estudos dos oceanos; planeamento agrícola; ordenamento do território e estudos do ambiente; e gestão de recursos hídricos (Rodrigues, 1992). Neste trabalho é de realçar a aplicação desta ciência non estudo do ordenamento do território. As imagens de satélite são fundamentais para os processos de classificação e ocupação do solo, pois permitem observar a realidade e perceber a complexidade subjacente aos fenómenos presentes na superfície terrestre; É, por isso, considerada uma ferramenta de referência para a tomada de decisão nos processos de ordenamento do território (Nandaia, 2015).




Figura 2- Elementos principais do processo de detecção remota. Fonte: Amorim (2015).

## 2.1 Radiação eletromagnética e interação energia-matéria

O objetivo central desta ciência baseia-se na transformação dos valores de refletância dos objetos à superfície terrestre, pelo que a radiação eletromagnética é um fator com uma função fundamental. Consiste no suporte de toda a informação e descreve as características físicas dos objetos presentes na superfície terrestre (Jensen, 2014; Nandaia, 2015).

A radiação eletromagnética resulta da combinação de dois campos: o elétrico e o magnético; Ambos se comportam como ondas que se propagam perpendicularmente entre si e relativamente à direção do movimento geral do campo eletromagnético (Amorim, 2015) (figura 3). O conjunto de todas as ondas eletromagnéticas designa-se por espectro eletromagnético, que inclui comprimentos de onda desde os raios gama, na ordem dos  $10^{-13}$  metros, às ondas de rádio, na ordem dos 100 metros (Amorim, 2015; Nandaia, 2015)(figura 4). A parte visível do espectro é considerada muito restrita e é detetável pelo olho humano; É formada por várias bandas de cores que vão desde o violeta até ao vermelho, ainda que as principais sejam a azul (0,4-0,5  $\mu\text{m}$ ), verde (0,5-0,6  $\mu\text{m}$ ) e vermelho (0,6-0,7  $\mu\text{m}$ ); A radiação infravermelha possui comprimentos de onda entre os 0,7  $\mu\text{m}$  e 100  $\mu\text{m}$  e corresponde ao conjunto de radiações compreendidas entre as bandas do visível e micro-ondas; Para a detecção remota importa, particularmente, o visível e o infravermelho próximo (0,7-3  $\mu\text{m}$ ) (Pinho, 2009).






Figura 3-Campo eletromagnético. Fonte: Amorim, 2015




Figura 4- Espectro eletromagnético da radiação solar. Fonte: Pinho (2009).

A interação entre a luz solar e os objetos à superfície da terra não depende apenas das características da luz que atinge os objetos, mas também da natureza dos mesmos; Isto pode originar diferentes comportamentos: a luz pode ser transmitida através dos objetos, pode ser absorvida, pode sofrer dispersão e pode ser refletida; A cor do objeto depende do comportamento de onda refletido (Pinho, 2009; Ribeiro, 2008).

## 2.2 Os tipos de resolução dos sensores

“A resolução de um sensor pode ser definida como a capacidade que este tem para apresentar uma imagem nítida e bem definida” (Pinho, 2009, p.18). Pode-se distinguir diferentes tipos de resolução de um sensor: a resolução espacial, a resolução temporal, a resolução espectral e a resolução radiométrica (Cracknell & Hayes, 2007; Jensen, 2014; Lillesand et al., 2015).

Os sensores que se encontram em plataformas espaciais (satélites) estão mais distantes da superfície terrestre e, por isso, têm uma maior cobertura espacial face a sensores colocados em plataformas aéreas ou terrestres, contudo não permitem obter tanto pormenor (Jensen, 2014; Nandaia, 2015). No entanto, o detalhe detetável numa imagem depende da resolução espacial do sensor, que tem em consideração a dimensão do objeto mais pequeno que ele consegue detetar e o campo de visão instantâneo (IFOV) (quanto menor for o IFOV maior é a resolução espacial de um

sensor e fornece o tamanho do pixel na superfície do solo) (Pinho, 2009). “Assim, a resolução espacial pode ser entendida como a distância mínima entre dois objetos que o sensor consegue distinguir no terreno e é definida pelo tamanho do pixel” (Pinho, 2009,p.18). Em termos gerais, a resolução espacial pode ser de ordem quilométrica, considerada resolução espacial baixa e de âmbito meteorológico ou oceanográfico, como o MODIS; da ordem das centenas ou dezenas de metros, considerada resolução espacial média a alta, presente nos sensores norte-americanos Landsat e no europeu SPOT; e inferior a 5 metros, considerada muito alta e de resolução das imagens multiespectrais dos sensores Quickbird, Ikonos e GeoEye (Amorim, 2015).

A resolução temporal refere-se à periodicidade com que o sensor adquire imagens da mesma área da superfície terrestre; Depende de um conjunto de fatores, de entre os quais, o ciclo de repetição, as capacidades de visualização do sensor, a sua cobertura espacial e a latitude (Salinero, 2007).

A resolução espectral diz respeito ao número de bandas espectrais de um sensor e à amplitude dos intervalos de comprimento de onda de cada banda; Quanto mais alta for a resolução espectral, mais rigorosas são as assinaturas espectrais obtidas (Mather, 2006; Rodrigues, 1992).

A resolução radiométrica define-se pelo número de valores digitais que representam níveis de cinza (Mather, 2006). Descreve a sensibilidade do sensor em detetar pequenas diferenças na energia refletida ou emitida (Pinho, 2009).

### **3. Satélites e sensores**

“Os sensores remotos são transportados por satélites artificiais, deslocando-se a diferentes velocidades e com diferentes altitudes orbitais, sendo as imagens por eles adquiridas condicionadas pelas características das plataformas e das suas órbitas” (Ribeiro, 2008, p.41).

Podemos destacar o programa de deteção remota por satélite LANDSAT. Este é um projeto que tem uma longa duração na história de aquisição de imagens da superfície terrestre e que tem sido continuamente melhorado ao longo do tempo (Amorim, 2015) (figura 5). O sensor LANDSAT 8 é o que, atualmente, se encontra operacional juntamente com o sensor LANDSAT 7, ainda que, em 2003, este último tenha perdido o sistema de correção SLC (Scan Line Corretor), o que leva a falhas nas imagens (Amorim, 2015; Rodrigues, 1992). O LANDSAT 8 foi lançado em 2013 e mantém as mesmas características que os anteriores em termos de órbita, em que faz uma translação completa a cada 98,9 minutos. A novidade face aos anteriores sensores é o facto de este possuir dois novos sensores: o OLI (Operational Land Image), que regista imagens com resolução espacial de 30 metros para as bandas visíveis, infravermelho próximo e médio e de 15 metros para a banda pancromática com três novas bandas; e o TIRS (Thermal Infrared Sensor), que fornece duas bandas térmicas com 100 metros de resolução espacial (Amorim, 2015). Constata-se, portanto, que os sensores LANDSAT adquirem

dados sob a forma de valores numéricos que correspondem à intensidade de energia refletida numa área de terreno de aproximadamente 30 por 30 metros ou de 60 por 60 metros (Amorim, 2015; Cracknell & Hayes, 2007).




Figura 5- Cronologia do Programa Landsat. Fonte: (Amorim, 2015).

Outros sensores importantes referir ao longo deste trabalho são os Sentinel. Estes estão associados ao programa Copernicus, um programa de observação da terra que fornece informações com o intuito de melhorar a gestão do meio ambiente. Este atua em seis domínios principais: oceanos, monitoramento da Terra, atmosfera, respostas de emergência, segurança e mudanças climáticas. Podemos enumerar seis sensores: Sentinel-1, que fornece todas as imagens de radar para serviços terrestres e marítimos; Sentinel-2, que fornece imagens óticas para serviços de Terra; Sentinel-3, que fornece dados óticos, de radar e de altimetria para serviços marítimos e terrestres; e Sentinel -4 e -5 responsáveis pelos dados para o monitoramento da composição atmosférica (Rodrigues, 1992).

Cada imagem recolhida por um sensor é captada com base num determinado intervalo espectral; A informação contida nas imagens de satélite apresenta-se sob a forma de pixéis cuja intensidade de cinzento representa um Número Digital (DN) que varia entre 0 e 255 (ex: imagens LANDSAT 7 com resolução radiométrica de 8 bits) ou entre 0 e 4095 (ex: imagem LANDSAT 8 com 12 bits de resolução radiométrica (Amorim, 2015). A natureza matricial das imagens de satélite permite trabalhá-las matematicamente e quantificar diferentes aspetos da natureza dos objetos e materiais; Se sobrepuermos diferentes imagens cada uma corresponde a um intervalo diferente do espectro eletromagnético; Combinações de bandas diferentes das que representam cores naturais (RGB) designam-se por falsa cor e permitem destacar diferentes objetos (Amorim, 2015; Cracknell & Hayes, 2007; Lillesand et al., 2015).

## **4. Processamento e análise de imagem**

As imagens enviadas pelos satélites através de sistemas de rádio para as estações em Terra possuem distorções que estão relacionadas, entre outros, com a rotação da Terra e distância do satélite à Terra, o que implica correções que têm procedimentos complexos. O processamento de imagens está incluído no conjunto de técnicas da detecção remota e permite extrair, manipular e quantificar a informação temática das mesmas (Amorim, 2015; Pinho, 2009; Ribeiro, 2008).

Os principais procedimentos a considerar no processamento de imagem são: descarregar a imagem; analisar a qualidade dos dados; manipular os dados; efetuar correções na imagem; efetuar operações de melhoramento da imagem; classificar a imagem e, por fim, analisar a exatidão da classificação da imagem.

### **4.1 Pré-processamento**

O pré-processamento tem como principais objetivos: compensar possíveis defeitos cosméticos, distorções geométricas, interferências atmosféricas de variações na iluminação, calibração das imagens por possível degradação do sensor, e correção dos valores dos pixels devido aos efeitos da topografia (Amorim, 2015). Ainda assim, grande parte destes procedimentos são realizados pela agência produtora dos dados, como é o caso das imagens LANDSAT.

Nesta fase, podem-se incluir correções radiométricas (reduzir erros e/ou distorções resultantes da interação da radiação com a atmosfera ou do efeito topográfico); correções geométricas (permitem reduzir distorções resultantes do movimento de rotação da Terra, da sua curvatura ou de variações na altitude do sensor); e correções atmosféricas (permitem remover efeitos da atmosfera na refletância através da utilização de vários modelos de correção. Pode-se destacar o modelo Dark Object Subtraction (DOS), que subtrai o objeto mais escuro por todos os pixels da imagem) (Amorim, 2015; Jensen, 2014; Lillesand et al., 2015).

### **4.2 Operações de melhoramento de imagem**

As técnicas de aprimoramento de imagem melhoram a qualidade da mesma como percebida pelo olho humano (Nandaia, 2015). Existem diversas técnicas que melhoram a qualidade da imagem, em que se destaca: a manipulação de contraste (limiar de nível de cinza; corte de nível; e alongamento de contraste), a manipulação de características espaciais (filtragem espacial; aprimoramento de borda; e análise de Fourier) e a manipulação de várias imagens (relação e diferenciação multispectral de bandas, vegetação e outros índices; componentes principais; componentes canónicos; componentes da vegetação; intensidade-matriz-saturação (IHS); e outras transformações no espaço

de cores) (Lillesand et al., 2015). Cada um destes processos é aplicado separadamente a cada banda de uma imagem multiespectral (Amorim, 2015; Cracknell & Hayes, 2007).

Através do histograma podemos, banda a banda, melhorar o brilho e o contraste, o que chamamos de transformação linear.

Através de filtros de imagem, que também são apelidados de filtros de suavização, podemos atenuar as diferenças entre pixels vizinhos (Nandaia, 2015). É de salientar o filtro pass baixo, que suaviza a imagem e em que normalmente são utilizados pixels 3 por 3; o filtro pass linear, que permite uma suavização, mas não com variações tão bruscas respeitando a tendência dos dados originais; e o filtro pass alto, considerado um filtro de contornos, em que define contornos horizontais, verticais e oblíquos.

Através de índices de imagens cria-se uma “camada de imagens sintética” a partir de bandas existentes de uma imagem multiespectral; Esta nova camada fornece informações únicas e valiosas que não foram encontradas em nenhuma das outras bandas (Lillesand et al., 2015). Um dos índices mais utilizados em detecção remota é o Normalized Difference Vegetation Index (NDVI) que permite determinar a atividade fotossintética. A sua fórmula de cálculo tem em atenção a banda do infravermelho próximo (NIR) e do vermelho (RED) (figura 6). Além deste, podemos também salientar o Soil Adjusted Vegetation Index (SAVI) que complementa o índice anteriormente referido (NDVI), uma vez que é menos sensível às mudanças na vegetação e mais sensível às diferenças atmosféricas. A sua fórmula de cálculo é mais complexa (figura 7). Além dos anteriormente mencionados e não menos importantes é de realçar também o Enhanced Vegetation Index (EVI); Soil Mixture Index (SMI), entre outros.

$$NDVI = \frac{\rho_{NIR} - \rho_{RED}}{\rho_{NIR} + \rho_{RED}}$$

Figura 6- Fórmula de cálculo do NDVI.

$$SAVI = \left( \frac{\rho_{NIR} - \rho_{RED}}{\rho_{NIR} + \rho_{RED} + L} \right) (1 + L)$$

Figura 7- Fórmula de cálculo do SAVI.

### 4.3 Classificação de imagem

O principal objetivo da classificação de imagem é categorizar de forma automática todos os pixels de uma imagem em classes de uso do solo (Lillesand et al., 2015). Assim, é possível substituir a análise visual da imagem por técnicas quantitativas para melhorar a identificação dos elementos na imagem (Cracknell & Hayes, 2007).

Este processo envolve uma análise multiespectral da imagem, bem como a aplicação de regras de decisão estatísticas (regras de decisão baseadas na radiância espectral dos dados ou nas formas geométricas, no tamanho e tipo de dados) (Amorim, 2015). Podemos distinguir dos tipos de

classificação: supervisionada e não-supervisionada (Cracknell & Hayes, 2007; Lillesand et al., 2015; Nandaia, 2015).

#### **4.3.1 Classificação supervisionada**

Na classificação supervisionada é feita uma análise espectral das características dos elementos da imagem. Os procedimentos a seguir são: visualizar uma única banda ou combinação RGB de três bandas; adquirir os conjuntos (áreas/classes) de treino; avaliar a separabilidade das classes; escolher o tipo de classificador (algoritmo); executar a classificação; refinar, caso necessário, os dados de treino; e calcular as medidas de avaliação da exatidão. Contudo, segundo Lillesand et al. (2015), podemos incluir todos estes procedimentos de uma forma mais resumida em três etapas: 1- Treino, em que o analista identifica áreas representativas de treino e desenvolve uma descrição numérica dos atributos espectrais de cada tipo de ocupação do solo de interesse; 2- Classificação, em que cada pixel no conjunto de dados de imagem é categorizado na classe de uso do solo que mais se assemelha. Caso o pixel não se assemelhe a nenhuma das classes definidas é categorizado como desconhecido; 3- Estado final/Avaliação de resultados, quando todos os pixels da imagem já foram categorizados. Os produtos finais podem ser mapas temáticos, tabelas estatísticas, entre outros, para as várias classes do uso do solo.

#### **4.3.2 Classificação não-supervisionada**

Este tipo de classificação requer pouca ou nenhuma intervenção do operador na classificação da imagem (Nandaia, 2015). Não existem áreas de treino pré-definidas e o algoritmo aplicado limita-se à identificação e separação de possíveis elementos da imagem através da análise da informação espectral existente (Amorim, 2015; Nandaia, 2015).

A importância deste tipo de classificação resulta, fundamentalmente, da necessidade em conhecer de forma rápida as classes de ocupação do solo presentes no espaço, cujo intuito é definir previamente quais as classes a extrair durante a fase do processamento de imagens (Nandaia, 2015).

Segundo Meneses & Almeida (2012), p.195, recorre-se a este tipo de classificação “ quando não se tem suficientes conhecimentos acerca da natureza das classes de alvos que possam estar presentes numa área; e quando desejamos fazer uma classificação exploratória da imagem, para rapidamente e sem grande esforço, saber as possíveis classes de alvos que podem ter na imagem”.

#### **4.4 Avaliação da precisão da classificação**

O processo de classificação da ocupação do solo pode ser moroso e é bastante complexo. Após o término da classificação de imagem e antes de prosseguir para outros empreendimentos é essencial avaliar a precisão dos resultados da classificação (Amorim, 2015; Lillesand et al., 2015). “Uma classificação não está completa até que a sua precisão seja avaliada” (Lillesand et al., 2015, p.576).

A exatidão do processo de classificação supervisionada é realizada através da análise de matrizes de erro/confusão. Estas comparam, classe a classe, a relação entre os pixels identificados nas áreas de treino e os pixels classificados automaticamente (Cracknell & Hayes, 2007; Lillesand et al., 2015). Os totais das linhas representam os resultados de classificação; os totais das colunas representam os dados de referência; e os elementos da diagonal representam os elementos corretamente classificados. Todos os elementos não diagonais da matriz representam erros de omissão ou comissão. Os erros de omissão estão associados à precisão do produtor (%) e os erros de comissão à precisão do utilizador (%). Assim, todos os elementos da diagonal correspondem a classes classificadas corretamente, enquanto que os elementos fora da diagonal correspondem a classes classificadas incorretamente (Cracknell & Hayes, 2007).

Outro parâmetro tido em consideração para avaliar a classificação é estatística Kappa. Tem em consideração a diferença entre a concordância real dos dados de referência com os dados que foram automaticamente classificados e a concordância hipotética entre os dados de referência e os aleatoriamente classificados (Amorim, 2015; Lillesand et al., 2015).

## 5. Apresentação e discussão dos resultados

### 5.1- Normalized Difference Vegetation Index (NDVI)

No caso do município de Arouca, em que 80% da sua área corresponde a espaços florestais, é possível verificar uma forte presença de vegetação, quer na época quente, quer na época fria (figura 8 e 9). Na época quente, os valores de NDVI variam entre -0,10 e 0,96 (tabela 2), em que se destaca essencialmente a classe do moderado e é mais notável áreas classificadas com NDVI baixo e muito baixo. Na época fria os valores variam entre -0,06 e 0,99 (tabela 2), sendo de realçar as classes do muito elevado, elevado e moderado (figura 8).

Tabela 2- Estatísticas do NDVI, na época quente e fria, no município de Arouca.

<b>Estatísticas</b>	<b>Inverno</b>	<b>Verão</b>
Média	0,71	0,62
Mediana	0,75	0,65
Desvio Padrão	0,19	0,19
Mínimo	-0,06	-0,10
Máximo	0,99	0,96

Assim, é notável uma ligeira diferença na presença de vegetação de uma época para a outra. O mês de agosto face ao mês de janeiro apresenta menor vegetação (figura 8 e 9). Isto justifica-se pelo facto de corresponder a uma época quente, com temperaturas mais elevadas resultado de uma maior incidência da radiação solar na superfície terrestre. Assim, a vegetação, sobretudo herbácea (carqueja, urze), apresenta-se mais seca, com folhas mortas e, por isso, com uma cor mais acastanhada, havendo menor refletância no NIR, mas por outro lado maior refletância no vermelho. Por outro lado, na época fria, que neste caso corresponde ao mês de janeiro, houve um período húmido anterior com elevada precipitação, o que resulta em vegetação mais saudável e, por isso, com aspeto mais “verde”. Neste caso há maior refletância no NIR.

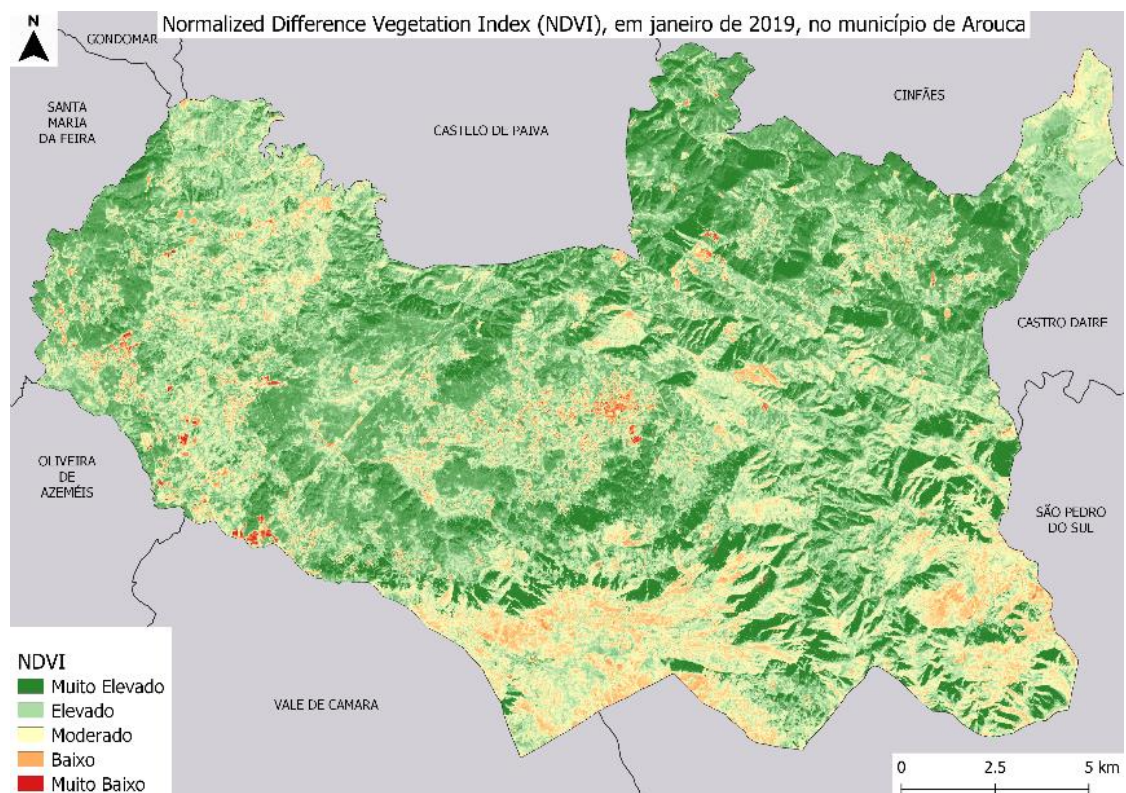


Figura 8- NDVI, na época fria (janeiro de 2019), no município de Arouca.



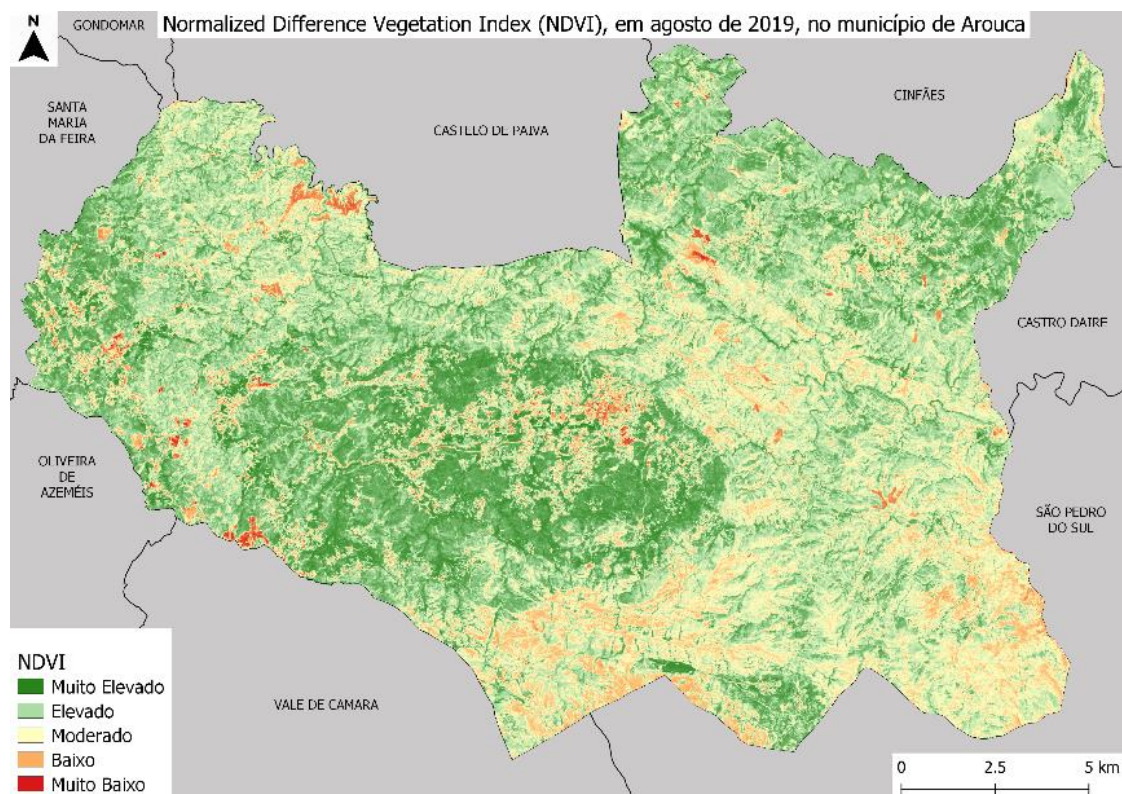


Figura 9- NDVI, na época quente (agosto de 2019), no município de Arouca.

Neste caso, em particular, outra situação que poderia influenciar os valores de NDVI e contribuir para uma menor presença de vegetação na época quente são os incêndios rurais. No ano de 2019 não foram registados incêndios neste município, contudo é um dos municípios que apresenta elevado risco de incêndio e elevada recorrência. Destacam-se os anos de 2005 e 2016 com elevada recorrência de incêndios, sobretudo incêndios extremos.

## 5.2 Classificação da ocupação do solo

As imagens classificadas, tendo em consideração o método de classificação supervisionada, apresentam pequenas diferenças tendo em consideração que a classificação da ocupação do solo se refere a dois períodos de tempo distintos do ano de 2019 (janeiro e setembro). As variações na ocupação do solo estão diretamente relacionadas com as condições meteorológicas mais ou menos contínuas, que antecedem a data de recolha das imagens. Portanto, a imagem recolhida no mês de janeiro de 2019, referente ao período de Inverno com períodos de precipitação mais intensos e frequentes dará origem a imagens onde a vegetação (herbáceas ou floresta) é mais verde e com enorme presença de água (figura 10). Em oposição a este período a imagem de setembro, recolhida após um período de verão com pouca precipitação, seco e de temperaturas altas poderá dar origem

a uma vegetação (herbáceas ou floresta) mais seca (figura 11). As variações das classes de ocupação do solo de janeiro para setembro de 2019 encontram-se expressas na tabela 3.

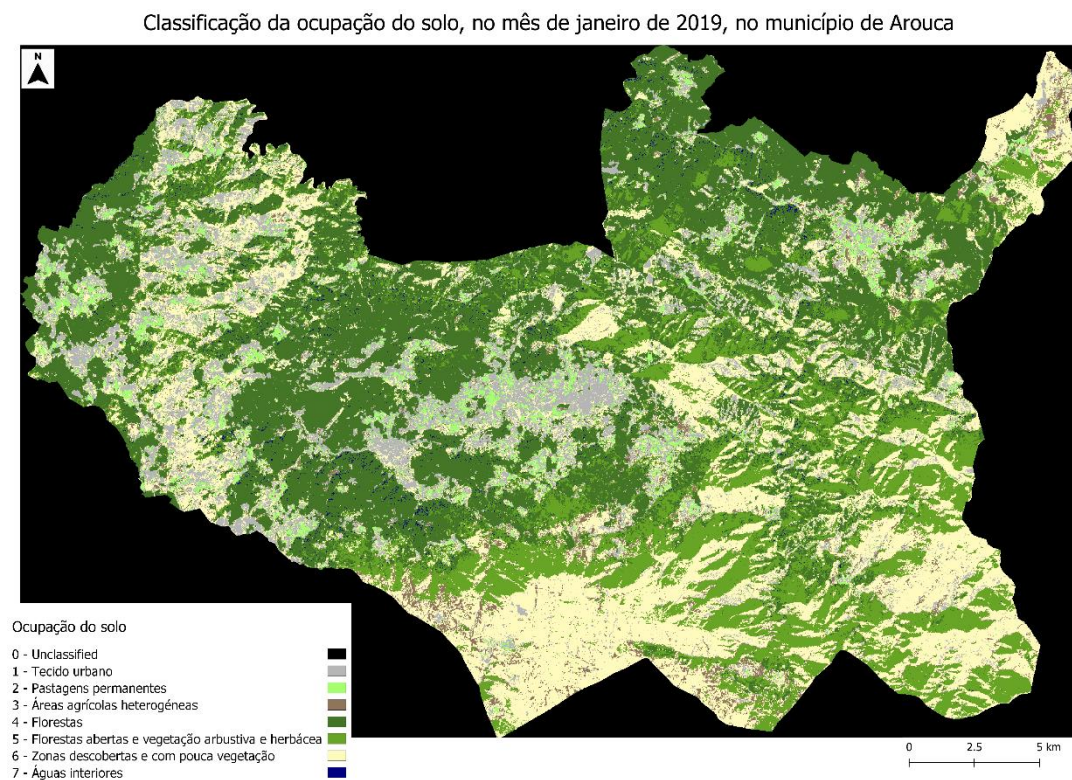


Figura 10- Classificação da ocupação do solo, no mês de janeiro de 2019, no município de Arouca.

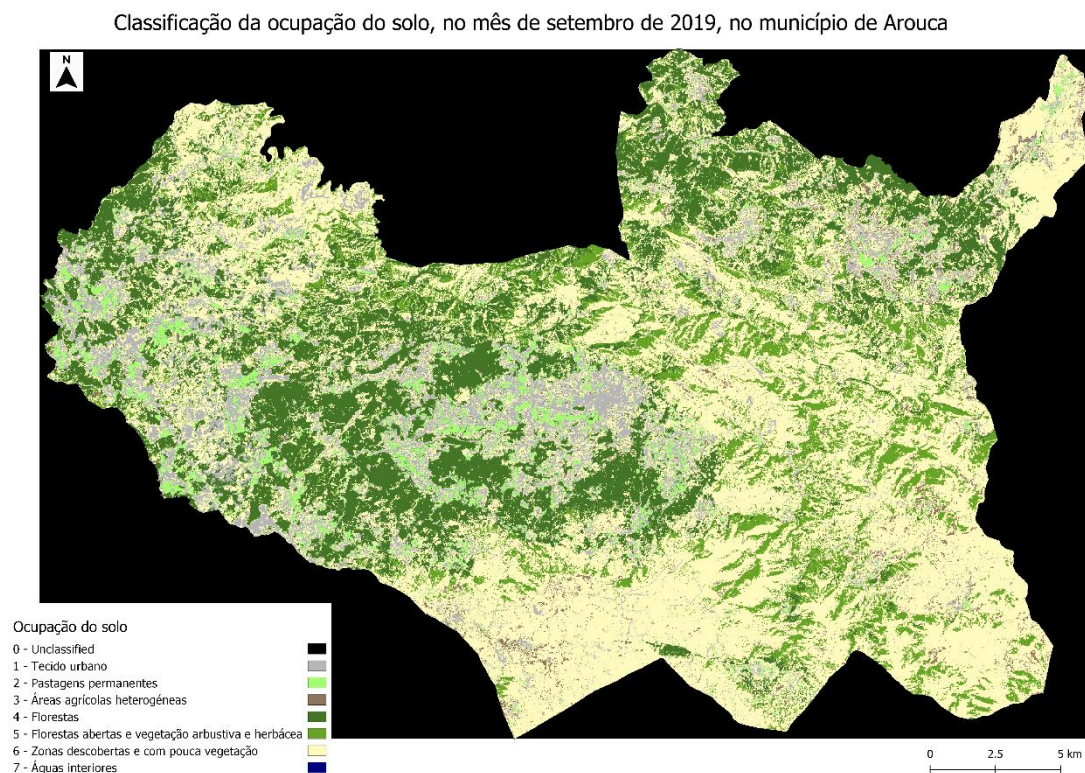


Figura 11- Classificação da ocupação do solo, no mês de setembro de 2019, no município de Arouca.



Tabela 3- Variações nas classes de ocupação do solo de janeiro para setembro de 2019 no município de Arouca

Classes de ocupação do solo	Variação %
Tecido urbano	-10,8
Pastagens Permanentes	18,8
Áreas agrícolas heterogêneas	-29
Florestas	-37
Florestas abertas e vegetação arbustiva e herbácea	-40,1
Zonas descobertas e com pouca vegetação	86,8
Águas interiores	-99,8

Contudo, segundo a classificação das imagens, as classes com maior expressão neste município são as zonas descobertas e com pouca vegetação que quase duplica a sua área e apresentam uma média entre os dois períodos de 12 584 ha, e as florestas e as florestas abertas e vegetação arbustiva e herbácea que apesar de serem as que apresentam uma maior variação negativa, em média, têm valores de 9 340 ha e 5 546 ha, respetivamente. As restantes classes como o tecido urbano que apresenta um decréscimo de 10,8%, não é possível encontrar justificação coerente que explique esta variação negativa neste curto período de tempo, a não ser uma possível confusão, na recolha dos dados pelos sensores, dos espectros emitidos pelos objetos. Contudo esta classe apresenta uma média de 3 502 ha. As pastagens permanentes e as áreas agrícolas heterogêneas as suas variações podem estar associadas ao ciclo agrícola de certas espécies cultivadas como o milho, batata, centeio e trigo. Contudo estas apresentam uma média de 1 174 ha e 717 ha respetivamente. É sempre importante lembrar que os espectros eletromagnéticos emitidos pelos objetos podem ter similaridades e ajudar a explicar as diferenças ou, as não realidades territoriais.

Por último, um aspeto importante de referir é a avaliação da precisão da classificação das imagens. Ambas as imagens foram classificadas tendo em consideração o método maximum likelihood. Considerando este método e as áreas de treino, foi gerada uma matriz de erro/confusão e um conjunto de estatísticas. Destaca-se o grau de exatidão global e o fator kappa. Na classificação de janeiro, o grau de exatidão global apresenta um valor de 48,28% e o fator kappa 0,42. Já na classificação de setembro, o grau de exatidão global é de 45,40% e o fator kappa 0,37. Apesar de os valores serem considerados relativamente baixos, e tendo em consideração o conhecimento da área de estudo, ambas as classificações correspondem à realidade territorial nos dois períodos em análise.

## 6. Conclusão

A detecção remota é uma boa ciência que pode, em âmbitos gerais, auxiliar nos processos de decisão das tarefas de ordenamento e planeamento do território. No entanto ela nunca mostrará com exatidão o uso e ocupação do solo e por isso se poderá considerar uma ciência meramente complementar.

Em traços gerais, o estado atual do planeamento e ordenamento do território, muitas vezes desajustado às realidades de um determinado território, que não responde eficientemente às suas necessidades quando feito meramente por técnico de laboratório que se baseiam em dados como as imagens de satélite pode levar a graves distorções do contexto local e à produção de políticas erráticas com efeitos indesejados.

Esta ciência é eficaz num planeamento que hoje em dia se busca cada vez mais ascendente e territorializado, já que na impossibilidade de mostrar a 100% as dinâmicas territoriais, a governança partilhada e participativa ajuda a corrigir os erros que as imagens têm com o conhecimento local efetivo por parte de quem o habita. Com esta junção da cartografia técnica e a correção partilhada, podemos ter uma representação gráfica do território o mais próximo de realidade possível, devidamente atualizada que seja a base da leitura correta dos técnicos competentes da tarefa do ordenamento do território.

## 6. Referências Bibliográficas

- Amorim, A. (2015). *Deteção remota e geoprocessamento automático no estudo da evolução de margens estuarinas (Estuário do Tejo)*.
- Correia, F. J. M. (2017). *O contributo dos serviços de ecossistema na prevenção e resiliência a incêndios rurais na Rede Natura 2000, no município de Arouca*.
- Cracknell, A., & Hayes, L. (2007). *Introduction to Remote Sensing*.
- INE. (2011). *Rel. téc. Instituto nacional de estatística*.
- Jensen, J. (2014). *Remote Sensing of the Environment An Earth Resource Perspective*.
- Lillesand, T., Kiefer, R., & Chipman, J. (2015). *Remote sensing and image interpretation*. Retrieved from [https://books.google.com.br/books?hl=pt-PT&lr=&id=AFHDCAAQBAJ&oi=fnd&pg=PA91&dq=REMOTE+SENSING+AND+IMAGE+INTERPRETATION&ots=0Curj\\_dyco&sig=mjVZpytdgucbBRNfZ1q3y52wBNU](https://books.google.com.br/books?hl=pt-PT&lr=&id=AFHDCAAQBAJ&oi=fnd&pg=PA91&dq=REMOTE+SENSING+AND+IMAGE+INTERPRETATION&ots=0Curj_dyco&sig=mjVZpytdgucbBRNfZ1q3y52wBNU)
- Magalhães, C. G. (2018). *A gestão dos incêndios rurais no município de Arouca: a relevância do conceito de defensabilidade*.
- Mather, P. (2006). *Computer Procesing of Remotely-Sensed Images*.
- Meneses, P., & Almeida, T. (2012). *Introdução ao processamento de Imagens de Sensoriamento Remoto*.
- Nandaia, M. (2015). *Os Sistemas de Informação Geográfica e Deteção Remota na Determinação das Regiões de Risco por Malária na Guiné-Bissau*.
- Pinho, R. (2009). *Aplicação de técnicas de detecção remota para a identificação de lineamento estruturais num sector do*

*noroeste de Portugal e do sudoeste da Galiza*. Retrieved from <https://repositorio-aberto.up.pt/handle/10216/14980>

Ribeiro, J. (2008). *A detecção remota no inventário florestal: análise das potencialidades da utilização das imagens de satélite*.

Rodrigues, F. (1992). *Deteção Remota*.

Salinero, E. (2007). *Teledetección Ambiental. La observación de la Tierra desde el Espacio*. (Ariel, Ed.). Barcelona.